Informe de Auditoría Científica y Plan de Corpus Legal

Proyecto: LeyIA DataScience — ¿Regular o no regular? Impacto de marcos regulatorios de IA en ecosistemas nacionales de IA **Fecha auditoría:** 2026-04-14 **Fecha informe consolidado:** 2026-04-15 **Estado proyecto:** Fase 1 (recolección) cerrada para variables numéricas · Corpus legal pendiente **Nivel de riesgo político: ALTO** — informa el Proyecto de Ley Marco IA Chile (16821-19)

Índice

1. Valoración global
2. Problemas críticos (bloqueantes para inferencia causal)
3. Problemas moderados
4. Fortalezas reconocidas
5. Estado post-Tarea A (abril 2026)
6. Plan detallado Tarea B — recodificación low-confidence
7. Plan detallado Tarea C — extracción corpus legal
8. Human-in-the-loop: qué hace el investigador, qué hace el sistema
9. Roadmap priorizado
10. Clasificación problemas × fase
11. Opinión franca

---

1. Valoración global

El proyecto tiene una **calidad infraestructural de nivel top-tier académico** (mejor que el 80% de los papers de política pública revisados). La trazabilidad documental (`DATA_DECISIONS_LOG.md` con 17 decisiones numeradas, `ETL_RUNBOOK.md`, 7 archivos `VARIABLES_*.md`, `SEGUIMIENTO_PAISES_MUESTRA.md`) es de calidad publicable en *Policy Sciences* o *Regulation & Governance*.

PERO existen **8 problemas metodológicos críticos** que, si no se resuelven antes de que este estudio informe la ley chilena, pueden producir **conclusiones causales inválidas** que el gobierno usaría para legislar mal.

---

2. Problemas críticos

🔴 PROBLEMA #1 — Endogeneidad / causalidad inversa *(el más grave)*

Diagnóstico: El diseño es *cross-section* 2025 con regulación y outcomes medidos contemporáneamente. Esto hace que la **dirección causal sea irresoluble estadísticamente**.

- Pregunta política: "*¿la regulación causa menor/mayor inversión, adopción e innovación?*"

- Pero el dataset también puede responder: "*los países con ecosistemas IA maduros desarrollan regulación (porque tienen algo que regular)*"
- **Ejemplo concreto**: la EU AI Act (2024) no causó la concentración de inversión IA en Alemania/Francia — Alemania/Francia **ya tenían** esa inversión y por eso la UE legisló. Confundir las dos historias es un error de primer año de econometría.

Fix obligatorio (orden de preferencia):

1. **Lag estructural** — Medir Y en 2025 pero X1 en 2022-2023 (año de promulgación, no vigencia). El campo `year_enacted` lo permite, pero no se está usando así.
2. **Difference-in-differences** con el panel `x1_consolidated.csv` (2013-2025, 902 rows) que ya existe. Este dataset es oro y se está ignorando en el análisis principal.
3. **Instrumental Variable** — Usar `oecd_member` o `region` como instrumento de `regulatory_intensity` (válido si la región determina adopción regulatoria por presión de pares, no por capacidad técnica).

Declaración honesta: Sin alguno de los 3 fixes, el paper solo puede hablar de **asociación**, no de **efecto**. Esto es **no negociable** para un policy paper.

Recomendación para Chile: No permitir que el gobierno cite este estudio como "*la regulación causa X*" sin uno de los 3 fixes. Un paper mal interpretado puede causar una mala ley.

🔴 PROBLEMA #2 — Tamaño muestral insuficiente para los grupos que más importan

Tabla `SEGUIMIENTO_PAISES_MUESTRA.md`:

Grupo regulatorio	N en muestra principal
binding_regulation	27
strategy_only	34
soft_framework	9
no_framework	**2**

Con **N=2 en `no_framework`** NO se puede hacer inferencia estadística comparativa. Un ANOVA o regresión con dummies tendrá ese grupo con varianza cero y errores estándar gigantes. Un referee rechazaría el paper en la primera ronda.

Irónicamente, el contraste que más le interesa a Chile sí es defendible: `strategy_only` (donde Chile está hoy, N=34) vs `binding_regulation` (a donde iría con la ley, N=27).

Fixes: 1. Colapsar a 3 grupos: `{no_framework + soft_framework}` vs `strategy_only` vs `binding_regulation` → (11, 34, 27). 2. Reportar *power analysis* explícito con `statsmodels.stats.power` para cada contraste. 3. Usar *bootstrap* / permutation tests en vez de t-tests paramétricos para grupos pequeños.

🔴 PROBLEMA #3 — El "EU AI Act block" contamina el análisis

En la codificación IAPP (`VARIABLES_IAPP.md:159`), los 27 miembros de la UE quedan codificados como `comprehensive` con `year_enacted=2024`. Tres problemas:

1. **No son observaciones independientes.** Alemania y Bulgaria "adoptaron" la misma regulación el mismo día. OLS trata esto como 27 puntos de datos cuando en realidad es **1 decisión política replicada 27 veces**.
2. **Rompe la varianza intra-grupo.** `binding_regulation` tiene 27 observaciones pero ~0 de variabilidad regulatoria dentro del bloque EU.
3. **Confunde regulación con "ser miembro UE"**, correlacionada con GDP, GII, readiness. Básicamente mide "*efecto UE*", no "*efecto de regular IA*".

Fixes (usar al menos 2): - *Cluster-robust standard errors* agrupados por `eu_bloc` (27 países UE + resto como singletons). - Efecto fijo EU: agregar dummy `is_eu_member` → absorbe el shock común. - Análisis dual: modelos con/sin UE, mostrando que los resultados sobreviven sin ella. - Submuestra "tratamiento temprano": CHN (2021), RUS (2020), PER (2023), KOR/JPN (2025) — países que regularon antes o fuera del bloque EU. Son el verdadero grupo de tratamiento natural.

🔴 PROBLEMA #4 — Confianza de codificación baja en 16 países

`VARIABLES_IAPP.md:147–150`:

> Confidence high: 36 · medium_needs_review: 32 · medium: 3 · **low: 16**

Los 16 `IAPP_FILL_GAP` con `confidence=low`: **BGD, BHR, BLR, BLZ, BRB, CMR, GHA, JOR, LBN, LKA, MNG, PAK, PAN, PHL, SYC, TWN**.

Esto significa que **~19% de la codificación regulatoria es débil**. Un referee pedirá: 1. *Inter-rater reliability* (Cohen's κ) — ¿un segundo codificador llega a las mismas categorías? 2. Análisis de sensibilidad excluyendo los 16 `low confidence`. 3. Validación externa contra ≥1 tercera fuente (FLI AI Policy Tracker, GPAI).

Plan: Ver Sección 6 (Plan detallado Tarea B).

🔴 PROBLEMA #5 — La Y principal está dominada por un outlier

`ai_investment_usd_bn_cumulative` (Stanford fig_4.3.9): - USA acumula **~60-70%** del total mundial 2013-2024 - China **~15%** - Los 82 países restantes se reparten el resto

Si se corre OLS sin transformar, **USA y CHN determinan todos los coeficientes**. El resto del modelo es ruido.

Fixes obligatorios: 1. `log(1 + ai_investment)` — verificar que `02_limpieza.ipynb` lo aplique sistemáticamente. 2. Per-capita o per-GDP: `ai_investment / gdp` es más interpretable y reduce el outlier effect. 3. Winsorizing al percentil 95/5 como análisis de sensibilidad. 4. Reportar resultados con y sin USA/CHN. Si los coeficientes cambian de signo, **la historia cambia**.

Lo mismo vale para `ai_startups_cumulative` (USA=6,000+, mediana global=15) y `ai_patents_per100k`.

🔴 PROBLEMA #6 — Confounders estructurales no controlados

Los controles X2 originales (`gdp_per_capita_ppp`, `internet_penetration`, `gii_score`, `oecd_member`, `region`) estaban bien pero faltaba un confounder crítico: **naturaleza del sistema legal y tradición regulatoria general**.

Un país *common-law* (EE.UU., UK) regula menos cualquier tecnología que un país *civil-law* (Alemania, Chile). Un país con alto `regulatory_quality` del WB regula IA no por IA, sino por **hábito institucional**.

Estado actualizado 2026-04 (ver Sección 5): Los 7 confounders prioritarios **ya fueron incorporados** en Tarea A:

Variable	Fuente	Status
`regulatory_quality`	WGI	✅ 85/86
`rule_of_law`	WGI	✅ 85/86
`has_gdpr_like_law`	DLA Piper 2025	✅ 86/86
`gdpr_similarity_level`	DLA Piper + EU adequacy	✅ 86/86
`fh_total_score` + `fh_democracy_level`	Freedom House FITW 2025	✅ 86/86
`legal_origin` + `is_common_law`	La Porta 2008	✅ 86/86
`ict_service_exports_pct` + `high_tech_exports_pct`	WDI	✅ 83/86

🔴 PROBLEMA #7 — Fase NLP subdimensionada

La pregunta Q4 ("*¿qué temas dominan el contenido regulatorio?*") requiere un corpus robusto. Pero en `GUIA_VARIABLES_ESTUDIO_ETL.md` se definían solo 15-20 documentos legales. Con ese tamaño: - **LDA no converge** bien (necesita ≥50-100 documentos para tópicos estables) - **TF-IDF funciona** pero es susceptible al idioma (corpus es multilingüe: español, inglés, chino, coreano, japonés, ruso...) - **Embeddings + clustering** funcionan mejor con pocos docs, pero **requieren documentos de verdad**, no codificación agregada

Problema más profundo detectado 2026-04-15: el proyecto **no tiene ningún documento legal descargado** en `data/raw/` por país. Solo reportes agregados (Stanford, Oxford PDFs). **X1 existe como metadatos (CSV) pero sin corpus textual subyacente.**

Plan: Ver Sección 7 (Plan detallado Tarea C).

🔴 PROBLEMA #8 — Chile no está tratado metodológicamente como "caso focal"

El proyecto se presenta como informante de la ley chilena, pero Chile aparece como **una más de las 72 observaciones** sin tratamiento especial. Para un policy brief gubernamental, esto es **insuficiente**.

Fix: incorporar análisis contrafactual específico de Chile:

1. **Synthetic Control Method** — construir un "Chile sintético" combinando países similares (Argentina, Uruguay, Costa Rica, Colombia) para simular qué pasa si Chile adopta `binding_regulation` vs queda en `strategy_only`.
2. **Matching** (propensity score o Mahalanobis) — identificar los 3-5 países más similares a Chile que sí legislaron, medir su trayectoria.
3. **Análisis de escenarios** — usar los coeficientes del modelo principal para predecir ΔY para Chile bajo 3 escenarios regulatorios.

Sin esto, el gobierno chileno solo obtiene "*hay una correlación global*" — no obtiene "*qué pasaría si Chile toma el camino X*", que es la única pregunta que les importa realmente.

---

3. Problemas moderados

🟡 #9 — Ventana temporal de controles inconsistente

`DATA_DECISIONS_LOG.md D-003` dice "*2019-2024 más reciente*". Pero un país tiene `internet_penetration=2019` y otro =2024. En *cross-section*, esto introduce ruido no aleatorio (países pobres tienen datos más antiguos).

Fix: forzar año específico (2022 o 2023) con imputación explícita para los 5-10 países faltantes usando regresión lineal de la serie país-específica.

🟡 #10 — `regulatory_intensity` como variable ordinal con escala arbitraria

La escala 0-10 es construcción propia (no estándar internacional). Reportar: - Matriz de ítems y pesos explícita (ya parcial en `VARIABLES_IAPP.md`). - Sensibilidad al esquema de ponderación. - Correlación con escalas externas (GPAI, OECD AIM, Stanford FMTI).

🟡 #11 — Falta imputación principled

11 países sin `ai_adoption_rate` (estructural en Microsoft). En vez de excluirlos: - **MICE** (Multiple Imputation by Chained Equations) usando `gii_score + gdp + internet + readiness` - Esto da **N=83** principal en vez de N=72. Gran aumento de poder estadístico. - Reportar con y sin imputación es el **estándar oro**.

🟡 #12 — No hay preregistro

Para un paper que informa legislación, el estándar post-reproducibility crisis: - Preregistrar en OSF.io las 4 hipótesis específicas antes de correr el modelo final. - Separar exploratorio (EDA libre) de confirmatorio (tests con Bonferroni o FDR). - Sin esto: acusación de *p-hacking* en peer review. 30 min de trabajo, defensa impecable.

🟡 #13 — Falta análisis de heterogeneidad

- Regresión por grupos: modelo separado para LATAM, EU, Asia-Pacífico, África.
- Interacciones: `regulatory_intensity × gdp_per_capita` — ¿la regulación afecta diferente a países ricos vs pobres?

- Le da AL GOBIERNO CHILENO una respuesta específica: "*en países del tamaño de Chile, la regulación X se asocia con Y*".

---

4. Fortalezas reconocidas

- **Documentación reproducible:** `DATA_DECISIONS_LOG` con 17 decisiones numeradas es mejor que la mayoría de papers publicados en *Nature Policy*.
- **Trazabilidad raw → interim → master → sample-ready:** arquitectura ETL limpia, auditable por cualquier tercero.
- **Sistema de muestras jerárquicas** (PRINCIPAL / CONFOUNDED / DIGITAL / REGIME / LEGAL_TRADITION / EXTENDED / STRICT) con flags binarios: exactamente lo que pide un revisor de JPART o Policy Sciences.
- Manejo honesto de Taiwan (D-004) y casos excepcionales.
- Reconciliación OECD vs IAPP con 4 status (AGREE / PARTIAL / DIVERGE / FILL_GAP): nivel de auditoría forense.
- Recuperación del gap Oxford 2024 via `pdfplumber`: solución ingeniosa y documentada.

---

5. Estado post-Tarea A (abril 2026)

Tarea A completada — 7 confounders institucionales incorporados al pipeline ETL. Snapshot actualizado:

Tier	N	Variables
PRINCIPAL (4Y + 5X1 + 5X2 core)	**72/86**	baseline
CONFOUNDED (+WGI_RQ + WGI_RL + GDPR-like) **[recomendada]**	**72/86**	separa calidad institucional + tradición digital pre-existente
DIGITAL (+ICT + high_tech exports)	69/86	robustness economía digital
REGIME (+FH score + democracy level)	72/86	robustness régimen político
LEGAL_TRADITION (+legal_origin La Porta)	72/86	robustness tradición jurídica
EXTENDED (+R&D + tertiary educ)	62/86	robustness capacidad absortiva
STRICT (+patents + gov_effectiveness)	47/86	robustness innovación + institucional

Dataset definitivo: `data/interim/sample_ready_cross_section.csv` (86 × 105 columnas).

Decisiones formalizadas D-012 a D-017 (ver `info_data/DATA_DECISIONS_LOG.md`): - D-012: WGI confounders - D-013: WGI expansion via DataBank db=3 - D-014: GDPR-like manual coding - D-015: Digital economy proxies - D-016: Freedom House regime - D-017: Legal origin La Porta

Lo que aún bloquea cierre de Fase 1: 1. Recodificar los 16 `confidence=low` de IAPP → **Tarea B** (Sección 6) 2. Extraer corpus legal textual por país → **Tarea C** (Sección 7)

---

6. Plan detallado Tarea B — recodificación low-confidence

6.1 Motivación

Los 16 países con `confidence=low` representan **~19% de la muestra principal** y su codificación actual está basada en **una sola fuente secundaria** (notas de prensa, noticias, wiki-entries). Esto genera:

- **Sesgo sistemático en X1.** El coeficiente de `regulatory_intensity` en OLS tiene ruido no aleatorio concentrado en países de renta baja/media.
- **Falta de evidencia textual verificable.** Un referee no puede inspeccionar la fuente.
- **Imposibilidad de análisis de sensibilidad.** No hay métrica de confianza para reportar.

6.2 Países objetivo (16)

ISO3	País	has_ai_law actual	approach actual	evidencia original
BGD	Bangladesh	0	strategy_led	nota de prensa
BHR	Bahrain	0	strategy_led	wiki + prensa
BLR	Belarus	0	light_touch	wiki
BLZ	Belize	0	none	sin evidencia positiva
BRB	Barbados	0	none	sin evidencia positiva
CMR	Cameroon	0	none	sin evidencia positiva
GHA	Ghana	0	strategy_led	nota de prensa
JOR	Jordan	0	strategy_led	comunicado oficial
LBN	Lebanon	0	none	sin evidencia positiva
LKA	Sri Lanka	0	light_touch	comunicado oficial
MNG	Mongolia	0	light_touch	wiki
PAK	Pakistan	0	strategy_led	comunicado oficial
PAN	Panama	0	strategy_led	comunicado oficial
PHL	Philippines	0	strategy_led	comunicado oficial
SYC	Seychelles	0	none	sin evidencia positiva
TWN	Taiwan	0	strategy_led	comunicado oficial

6.3 Decisión metodológica clave (2026-04-15)

Tarea B y Tarea C se fusionan parcialmente. No tiene sentido "recodificar con alta confianza" sin leer el documento fuente. Por tanto, la ejecución real será:

1. Para cada uno de los 16 países, **localizar y descargar el documento oficial** (ley, estrategia, lineamiento vigente) desde el sitio del gobierno.
2. Si el documento existe → descargar, leer, **recodificar con evidencia textual citada**.
3. Si no se encuentra → `has_ai_law=0` con `confidence=high`, justificación: "búsqueda exhaustiva sin resultados".

4. Guardar documento + metadata en `data/raw/legal_corpus/{ISO3}/` (ver esquema Sección 7.4).

Esto convierte Tarea B en **el piloto de Tarea C**: deja el terreno preparado para hacer la extracción completa con los ~70 países restantes.

6.4 Rúbrica de codificación formal

Para cada variable, criterio explícito:

`has_ai_law` (0/1)

- **1** ↔ existe instrumento legal vinculante específico para IA (ley, decreto con fuerza de ley, reglamento con sanciones). **NO** cuenta: estrategia nacional, lineamientos voluntarios, marco ético no-vinculante.
- **0** ↔ no existe instrumento vinculante al 2025-Q4.
- Regulación sectorial (solo fintech, solo salud) → `has_ai_law=0`, se captura en `regulatory_approach=light_touch`.
- Regulación de datos personales que menciona IA → `has_ai_law=0` (ya capturado por `gdpr_similarity_level`).

`regulatory_approach` (categorical)

- `none` — no hay ley, estrategia ni lineamientos formales.
- `light_touch` — solo lineamientos no-vinculantes o regulación sectorial parcial.
- `strategy_led` — estrategia nacional formal publicada por gobierno, sin ley vinculante.
- `regulation_focused` — ley vinculante parcial (solo ciertos sectores o ciertas obligaciones).
- `comprehensive` — ley horizontal comprehensiva (EU AI Act, Colorado AI Act, CAC regulations).

`regulatory_intensity` (0-10)

Suma ponderada de: - Existencia de ley (0-3): 0=no, 1=draft, 2=sectorial, 3=horizontal - Obligaciones concretas (0-3): 0=ninguna, 1=transparencia, 2=+evaluación, 3=+restricciones - Sanciones (0-2): 0=sin sanciones, 1=administrativas, 2=penales/multas materiales - Autoridad competente (0-2): 0=sin autoridad, 1=órgano existente adaptado, 2=autoridad ad-hoc

`enforcement_level` (ordinal: none/low/medium/high)

- `none` — sin autoridad competente
- `low` — autoridad existe pero sin sanciones registradas públicamente
- `medium` — ≥1 caso de enforcement público
- `high` — múltiples casos + multas materiales

`thematic_coverage` (0-15)

Conteo de tópicos cubiertos por el instrumento: {transparency, bias/discrimination, privacy, safety, accountability, human_oversight, risk_assessment, sectoral_carveouts, high_risk_systems, foundation_models, copyright_AI, deepfakes, labor_AI, public_procurement, sandboxes}.

6.5 Jerarquía de fuentes (niveles 1-7)

Nivel	Fuente	Ejemplos
1 (máxima)	Sitio oficial del gobierno	`.gov.xx`, `.gouv.xx`, portal parlamentario, diario oficial
2	OECD AI Policy Observatory	`oecd.ai/countries`
3	Global Partnership on AI (GPAI)	`gpai.ai` country reports
4	FLI AI Policy Tracker	`futureoflife.org/ai-policy`
5	UNESCO AI Ethics Observatory	`unesco.org/ethics-ai`
6	Stanford HAI country profiles	`aiindex.stanford.edu`
7	Prensa especializada	MIT Tech Review, Reuters, Bloomberg

Regla de confianza: - `high` → ≥2 fuentes de nivel 1-3 concuerdan + documento primario guardado - `medium` → 1 fuente nivel 1-3 + 1 nivel 4-6 concuerdan - `low` → solo nivel 4-7 o fuentes que se contradicen

6.6 Output esperado

Archivo `data/raw/IAPP/manual_coding/recoding_v2.csv` con columnas:

Columna	Tipo	Descripción
iso3	string	—
has_ai_law_v2	0/1	codificación re-verificada
regulatory_approach_v2	categorical	—
regulatory_intensity_v2	0-10	—
enforcement_level_v2	ordinal	—
thematic_coverage_v2	0-15	—
year_enacted_v2	int	año del instrumento principal (NULL si has_ai_law_v2=0)
confidence_v2	high/medium/low	según regla Sección 6.5
source_primary_url	string	URL documento primario
source_primary_title	string	—
source_primary_type	L/S/G/D/none	Ley, Strategy, Guideline, Draft, none
source_secondary_urls	list[string]	URLs adicionales de validación
evidence_quote	text	cita textual (≤200 chars)
recoding_date	date	—
recoding_changed	bool	flag si cambia vs IAPP original
change_justification	text	si `recoding_changed=true`

6.7 Flujo de trabajo (human-in-the-loop)

1. **Sistema (Claude):** preparar rúbrica formal → `info_data/METODOLOGIA_RECODIFICACION_IAPP.md`
2. **Humano:** aprobar rúbrica + criterios de borde de Sección 6.4

3. **Sistema:** para cada país, ejecutar búsqueda sistemática vía WebFetch/WebSearch en la jerarquía de fuentes. Descargar documento primario si existe. Rellenar fila en `recoding_v2.csv`.
4. **Sistema:** generar tabla de propuestas de cambio (países donde `recoding_changed=true`).
5. **Humano:** revisar caso por caso. Para cada propuesta de cambio: - Aceptar (la nueva evidencia es superior) - Rechazar (la original era correcta, rechazar nueva evidencia) - Pedir más evidencia (sistema hace búsqueda adicional)
6. **Sistema:** aplicar cambios aprobados, actualizar `x1_master.csv`, regenerar `sample_ready_cross_section.csv`, documentar en `D-018`.
7. **Sistema:** análisis de sensibilidad: correr modelo principal con y sin los 16 países, reportar estabilidad de coeficientes.

Tiempo estimado: - Sistema: 4-6h (búsqueda + descarga + codificación) - Humano: 40-60 min (revisión de propuestas)

---

7. Plan detallado Tarea C — extracción corpus legal

7.1 Motivación y alcance

Objetivo: construir un corpus legal textual **por país** que permita: 1. Análisis NLP (LDA / embeddings / TF-IDF) de contenido regulatorio (pregunta Q4) 2. Validación textual de la codificación X1 (backing para Tarea B) 3. Comparación temática cross-país 4. Publicación reproducible (otros investigadores pueden verificar el texto que codificamos)

Restricción explícita del usuario: *incluir solo leyes y estrategias vigentes*. Excluir borradores no aprobados, documentos obsoletos, versiones derogadas.

7.2 Universo del corpus

Para los 86 países + 1 bloque EU:

Tipo	Código	Ejemplo	Criterio
Ley vinculante	L	EU AI Act, Colorado AI Act, CAC Generative AI Regulation	Vigente al 2025-Q4
Estrategia nacional	S	Chile "Política Nacional de IA" 2021	Oficialmente publicada por gobierno
Reglamento derivado	R	EU AI Act Implementing Regulations	Vigente
Lineamiento formal	G	NIST AI RMF 1.0 (EE.UU.)	Emitido por autoridad pública
Excluidos	—	drafts, borradores, propuestas, whitepapers académicos	—

Meta cuantitativa: 80-150 documentos totales. Un país puede tener 0 (ej: no_framework), 1 (ley o estrategia), o múltiples (EU = 1 AI Act + 27 estrategias nacionales).

7.3 Jerarquía de capas (3-layer source hierarchy)

Capa 1 — Índice (descubrir qué documentos existen): - OECD.AI Policy Observatory — lista oficial de instrumentos por país - IAPP Global AI Law & Policy Tracker (PDF Feb 2026) - GPAI country reports

Capa 2 — Verificación (confirmar que el documento existe y está vigente): - EUR-Lex (para EU AI Act y derivados) - Bases de datos legales nacionales (Biblioteca del Congreso Chile, LexisNexis, national gazettes) - Archivos parlamentarios

Capa 3 — Descarga (obtener el documento primario): - **Sitio oficial del gobierno** (requisito hard — sin excepciones) - Formato preferido: PDF oficial > HTML gubernamental > texto en gazette oficial

Principio rector: *trust but verify*. Capa 1 dice "Bangladesh tiene estrategia X". Capa 2 confirma vigencia. Capa 3 baja el PDF desde el sitio del Ministerio de Ciencia de Bangladesh (no desde un aggregator).

7.4 Estructura de almacenamiento

```
data/raw/legal_corpus/
├── manifest.csv                    # índice maestro de todos los documentos
├── EU/
│   ├── EU_L_001_ai_act_2024.pdf
│   ├── EU_L_001_ai_act_2024.meta.json
│   └── EU_L_001_ai_act_2024.txt    # texto extraído (OCR si necesario)
├── CHL/
│   ├── CHL_S_001_politica_nacional_ia_2021.pdf
│   ├── CHL_S_001_politica_nacional_ia_2021.meta.json
│   └── CHL_S_001_politica_nacional_ia_2021.txt
├── USA/
│   ├── USA_G_001_nist_ai_rmf_2023.pdf
│   ├── USA_L_001_colorado_ai_act_2024.pdf
│   └── ...
├── CHN/
│   ├── CHN_L_001_cac_gen_ai_2023.pdf
│   ├── CHN_L_002_cac_algorithmic_recs_2022.pdf
│   └── CHN_L_003_cac_deep_synthesis_2023.pdf
└── ...
```

Esquema `manifest.csv`:

Columna	Tipo	Descripción
doc_id	string	`{ISO3}_{TYPE}_{NNN}` ej: `CHL_S_001`
iso3	string	país o `EU`
jurisdiction_name	string	—
doc_type	L/S/R/G	ley / estrategia / reglamento / lineamiento
doc_title_original	string	título oficial en idioma original
doc_title_english	string	título traducido
year_enacted	int	año de promulgación
year_last_amended	int	última modificación vigente
still_in_force	bool	validado por humano
language_original	string	ISO 639-1
source_url_official	string	URL sitio gobierno
source_url_mirror	string	URL secundaria (EUR-Lex, OECD.AI)
download_date	date	—
file_format	string	pdf/html/docx/txt
file_size_bytes	int	—
file_sha256	string	hash para deduplicación
pages	int	—
word_count_original	int	—
word_count_english	int	—
extraction_method	string	pdfplumber / OCR / html_parser
human_verified	bool	flag human-in-the-loop
human_verifier_date	date	—
human_verifier_notes	text	—
corpus_tier	core/extended	core = usa para análisis principal

Esquema `{doc_id}.meta.json`: copia estructurada de la fila manifest + resumen + TOC extraído.

7.5 Pipeline de extracción

Tres scripts nuevos en `src/`:

`src/fetch_ai_corpus.py` (descarga)

- Input: registro por país con URLs candidatas
- Acciones: descarga respetando `robots.txt`, calcula SHA-256, guarda raw + metadata preliminar
- Output: archivos en `data/raw/legal_corpus/{ISO3}/`
- **Human-in-the-loop:** antes de descargar, presenta al humano la lista de URLs candidatas y pide confirmación (checkbox UI simple) → evita descargar drafts, versiones obsoletas, documentos erróneos

`src/parse_ai_corpus.py` **(extracción de texto)**

- Input: archivos raw en `data/raw/legal_corpus/`
- Acciones: `pdfplumber` para PDFs, `BeautifulSoup` para HTML, OCR con Tesseract para PDFs escaneados
- Output: archivo `.txt` paralelo por cada documento
- Validación: word count > umbral mínimo (descarta extracciones fallidas)

`src/translate_ai_corpus.py` **(traducción unificada)**

- Input: `.txt` en idioma original
- Acciones: traducción a inglés vía **DeepL API** (costo estimado ~$70 one-time para corpus completo)
- Output: `.en.txt` paralelo
- Cache por SHA-256 para no traducir el mismo documento dos veces

7.6 Quality Gates (8 verificaciones)

Gate	Verificación	Umbral
G1	SHA-256 único por documento	100%
G2	`source_url_official` apunta a dominio gubernamental autoritativo	100%
G3	`still_in_force=true` verificado manualmente por humano	100%
G4	`word_count_original` ≥ 500 palabras (filtra PDFs vacíos o scans fallidos)	≥95%
G5	`language_original` detectado vía `langdetect` coincide con país esperado	≥95%
G6	Traducción al inglés no corrupta (word_count_english > 0.5× word_count_original)	≥95%
G7	Cobertura: cada país con `has_ai_law=1` OR `regulatory_approach=strategy_led` tiene ≥1 documento	100%
G8	`human_verified=true` en todos los documentos del corpus core	100%

7.7 Casos especiales

EU (27 países + EUU): - 1 entrada `EU_L_001_ai_act_2024` (nivel bloque) - 27 entradas `{ISO3}_S_001_national_strategy` (estrategias nacionales individuales) - En el análisis: los 27 países comparten `has_ai_law=1` vía EU AI Act, pero su estrategia nacional es independiente

USA: - 1 entrada `USA_G_001_nist_ai_rmf_2023` (federal, no vinculante) - 1 entrada `USA_L_001_colorado_ai_act_2024` (estadual vinculante) - 1 entrada `USA_S_001_national_ai_rd_plan_2023` - `has_ai_law=0` a nivel federal, pero se documenta la fragmentación

China: - 3 entradas separadas por CAC (Cyberspace Administration of China): - `CHN_L_001_cac_generative_ai_2023` - `CHN_L_002_cac_algorithmic_recommendations_2022` - `CHN_L_003_cac_deep_synthesis_2023` - Tratadas como 3 instrumentos → `has_ai_law=1`, `regulatory_approach=comprehensive`

Países sin documento: - No hay fila en manifest - `has_ai_law=0` con `confidence=high` justificado por "búsqueda exhaustiva sin resultados en Capa 1 y 3"

7.8 Human-in-the-loop explícito

Este punto es **no negociable** por decisión del usuario: "*esta extracción no sería 100% automática, tiene que haber intervención humana para evitar descargar archivos incorrectos, antiguos o que ya no están en vigencia*".

Puntos de intervención humana obligatoria:

Paso	Acción del humano	Tiempo estimado
Antes de descarga	Revisar lista de URLs candidatas por país y confirmar/rechazar cada una	30-60 min por país × 86 = 40-80h (puede distribuirse)
Post-descarga	Abrir el documento y verificar: (a) está vigente, (b) es el documento que el sistema cree que es, (c) no es un borrador	10-15 min por documento × ~100 = 15-25h
Post-traducción	Spot-check de 10-15% de traducciones (~10-15 documentos)	3-5h
Pre-análisis NLP	Validar que el corpus final cumple los 8 Quality Gates	2-3h
Total humano		**60-110h** (fase distribuida en 4-6 semanas)

Por qué la intervención humana es crítica: - **Vigencia:** un LLM puede bajar un borrador 2022 creyéndolo ley 2024. Solo un humano verifica la fecha de entrada en vigor contra el diario oficial. - **Autenticidad:** sitios espejo pueden publicar versiones con texto alterado. Solo el humano valida que el PDF es el oficial. - **Contexto político:** Chile 2021 tiene "Política Nacional de IA" pero también un proyecto de ley 2024 (16821-19). Solo el humano decide qué cuenta como "instrumento vigente" para el corpus. - **Traducciones sensibles:** términos legales en chino/ruso/árabe pueden tener múltiples traducciones. Humano spot-check en los casos ambiguos.

7.9 Análisis NLP posterior (fase posterior al corpus)

Una vez corpus cerrado y validado:

1. **Preprocessing:** tokenización, lematización, stopwords legales (en inglés post-traducción)
2. **TF-IDF** para términos distintivos por país y por grupo regulatorio
3. **Embeddings** multilingües vía Sentence-BERT `paraphrase-multilingual-mpnet-base-v2` (alternativa: `Legal-BERT`, `E5-multilingual`)
4. **Clustering temático** (K-Means sobre embeddings) → valida taxonomía de `thematic_coverage`
5. **LDA** (Latent Dirichlet Allocation) — solo si N ≥ 80 (necesita tamaño mínimo para convergencia)
6. **Validación humana de tópicos:** top 20 términos por tópico → experto legal los nombra

7.10 Timeline Tarea C

Semana	Actividad	Sistema	Humano
1	Construir `manifest.csv` preliminar con URLs candidatas por país (Capa 1)	6h	0h
2	Revisión humana de URLs candidatas	0h	15-20h
3	Descarga masiva post-aprobación	4h	5h (spot-checks)
4	Extracción de texto + traducción DeepL	3h	10h (verificación)
5	Quality Gates + validación humana final	2h	5h
6	Análisis NLP preliminar + validación tópicos	8h	5h
Total		**~23h**	**~40-50h**

---

8. Human-in-the-loop

Esta sección consolida **qué tiene que hacer el usuario** vs **qué hace el sistema** a lo largo de B y C.

8.1 Roles

Sistema (Claude): - Buscar fuentes vía WebFetch/WebSearch - Descargar documentos (con confirmación previa) - Extraer texto (pdfplumber / OCR / HTML parsing) - Traducir (DeepL API) - Codificar variables X1 siguiendo rúbrica - Calcular SHA-256, metadata técnica, Quality Gates - Generar tabla de propuestas de cambio - Correr análisis de sensibilidad - Ejecutar NLP final

Humano (investigador): - Aprobar rúbrica y criterios de borde antes de empezar - Revisar URLs candidatas por país (confirmar cuáles son oficiales vs descartar) - Verificar vigencia de cada documento descargado (fecha entrada en vigor, versión actual, no es borrador) - Decidir casos ambiguos (Chile: estrategia 2021 + proyecto ley 2024 → ¿qué entra al corpus?) - Spot-check traducciones - Validar los 8 Quality Gates finales - Nombrar tópicos LDA/embedding post-análisis - Aprobar/rechazar propuestas de cambio de codificación

8.2 Qué NO debe subir el usuario al repo

Nada físicamente. El sistema tiene capacidad para: - Buscar fuentes en internet (WebSearch) - Descargar documentos (WebFetch) - Leer PDFs (pdfplumber / OCR) - Traducir (llamando DeepL API)

El usuario **no necesita descargar manualmente** ni un solo PDF. Su rol es de **validador y decisor**, no de recolector.

8.3 Qué SÍ tiene que proveer el usuario

Input	Quién lo da	Cuándo
Key DeepL API	Usuario (~$70 one-time)	Antes de Tarea C Semana 4
Aprobación de rúbrica B	Usuario	Antes de Tarea B ejecución
Aprobación de jerarquía de fuentes	Usuario	Antes de Tarea B ejecución
Confirmación de URLs candidatas	Usuario	Tarea C Semana 2 (iterativo por país)
Verificación de vigencia	Usuario	Tarea C Semana 3 (iterativo por documento)
Revisión de propuestas de cambio	Usuario	Tarea B cierre
Nombres de tópicos NLP	Usuario	Tarea C Semana 6

8.4 Interfaz de revisión humana propuesta

Para hacer el trabajo del humano **tractable**, el sistema generará archivos de decisión con checkbox en formato `.md` o CSV:

```
# Revisión URLs candidatas — BGD (Bangladesh)

## Candidata 1
- URL: https://ict.gov.bd/policies/national-ai-strategy-2024
- Título: Bangladesh National AI Strategy (2024-2030)
- Nivel fuente: 1 (sitio oficial Ministry of ICT)
- Fecha documento: 2024-07-15
- Decisión: [ ] Aprobar · [ ] Rechazar · [ ] Más evidencia
- Notas: __________

## Candidata 2
- URL: https://oecd.ai/en/dashboards/countries/Bangladesh
- Título: OECD AI country profile — Bangladesh
- Nivel fuente: 2
- Fecha documento: 2025-01
- Decisión: [x] Aprobar (como validación secundaria) · [ ] Rechazar
- Notas: Confirma que estrategia nacional existe y está vigente
```

El usuario revisa, marca, y el sistema procesa en batch.

---

9. Roadmap priorizado

Fase 1 (recolección) — restante

Semana en curso (2026-04-15 — 2026-04-22): - ✅ Tarea A (7 confounders) — **COMPLETADA** - ⏳ Tarea B (recodificar 16 low-confidence) + descarga inicial para esos 16 países - ⏳ Tarea C Semana 1: construir manifest preliminar

Semanas 2-3 (2026-04-22 — 2026-05-06): - ⏳ Tarea C Semanas 2-3: revisión humana + descarga masiva

Semana 4 (2026-05-06 — 2026-05-13): - ⏳ Tarea C Semana 4: extracción texto + traducción

Semana 5 (2026-05-13 — 2026-05-20): - ⏳ Tarea C Semanas 5-6: QG + NLP preliminar

Fase 2 (limpieza) — post-Fase 1

- Aplicar `log(1 + ai_investment)` sistemáticamente (#5)
- Normalización per-capita / per-GDP (#5)
- Winsorizing p95/p5 (#5)
- Forzar ventana temporal 2022-2023 con imputación explícita (#9)
- Imputación MICE para 11 países sin `ai_adoption_rate` (#11)
- Análisis de sensibilidad al esquema de ponderación (#10)

Fase 3 (EDA confirmatorio)

- Preregistro OSF con 4 hipótesis específicas (#12)
- Separación exploratorio vs confirmatorio

Fase 4 (modelamiento)

- OLS con lags temporales (#1, fix principal endogeneidad)
- Difference-in-differences con `x1_consolidated.csv` panel (#1)
- Instrumental Variables (#1)
- Cluster-robust SE por `eu_bloc` (#3)
- Dummy `is_eu_member` (#3)
- Análisis con/sin UE, con/sin USA+CHN (#3, #5)
- Power analysis por contraste (#2)
- Synthetic Control Method para Chile (#8)
- Matching / Mahalanobis para Chile (#8)
- Análisis de heterogeneidad regional e interacciones (#13)

Fase 5 (entregable)

- Paper para Research Policy / Policy Sciences / Regulation & Governance
- Policy brief específico para Chile (5-10 páginas, no técnico)

---

10. Clasificación problemas × fase

#	Problema	Severidad	Fase resolución	¿Requiere más recolección?	Estado
#1	Endogeneidad	🔴	Fase 4	❌ usa `x1_consolidated.csv` panel existente	Pendiente
#2	N por grupo	🔴	Fase 4 + reclasificar	🟡 parcial	Pendiente
#3	Bloque EU	🔴	Fase 4	❌	Pendiente
#4	confidence=low	🔴	**Fase 1**	✅ Tarea B	**En curso**
#5	Outliers USA/CHN	🔴	Fase 2	❌	Pendiente
#6	Confounders faltantes	🔴	**Fase 1**	✅ Tarea A	✅ **COMPLETADA**
#7	Corpus NLP	🔴	**Fase 1**	✅ Tarea C	**Planificada**
#8	Chile caso focal	🔴	Fase 4	❌	Pendiente
#9	Ventana temporal	🟡	Fase 2	❌	Pendiente
#10	Escala `regulatory_intensity`	🟡	Fase 2 + 4	❌	Pendiente
#11	Imputación MICE	🟡	Fase 2	❌	Pendiente
#12	Preregistro	🟡	Fase 3	❌	Pendiente
#13	Heterogeneidad	🟡	Fase 4	❌	Pendiente

Conclusión: Solo 3 de los 13 problemas son realmente de Fase 1 — #4 (en curso), #6 (completado), #7 (planificado). Los demás se abordan en fases posteriores.

---

11. Opinión franca

Este proyecto va en buen camino pero **NO está listo**. La infraestructura de datos es de élite, pero la arquitectura de inferencia causal es débil. Un *cross-section* con N=72 contaminado por el bloque UE no puede responder "*¿Chile debe regular?*" con rigor científico.

Si se publica el paper como está hoy: - Probable rechazo en revistas Q1 (Research Policy, Policy Sciences). - El gobierno chileno podría usarlo mal, exagerando asociaciones como si fueran efectos causales.

Si se implementan los 8 problemas críticos: - El paper puede ser publicable en Research Policy, Policy Sciences o Regulation & Governance. - El proyecto puede fundamentar la ley 16821-19 con solidez científica defensible.

Prioridades inmediatas (próximas 4 semanas): 1. **Endogeneidad (#1)** — fix no requiere recolección adicional, sí requiere diseño de modelo. Crítico para Fase 4. 2. **Corpus legal (#7, #4 fusionados)** — única brecha real de Fase 1 que queda abierta. Sin corpus, el paper es "descriptivo con evidencia agregada"; con corpus es "estudio reproducible con evidencia primaria". 3. **Chile como caso focal**

(#8) — diferencia entre "paper académico sobre 86 países" y "paper que informa una ley específica". Es la única razón por la que este proyecto tiene riesgo político alto.

Si algo tuviera que priorizarse por encima del resto: cerrar Tarea B+C (corpus legal con validación humana). Es lo único que: - Todavía es parte de Fase 1 (no se puede posponer) - No puede ejecutarse sin el usuario (human-in-the-loop obligatorio) - Da evidencia primaria verificable por cualquier tercero

Todo lo demás (modelamiento, Synthetic Control, preregistro) puede esperar hasta tener corpus cerrado.

Historial del informe

Fecha	Acción
2026-04-14	Auditoría científica original (13 problemas identificados)
2026-04-15	Tarea A cerrada (problema #6 resuelto: 7 confounders incorporados)
2026-04-15	Plan B+C consolidado con human-in-the-loop explícito (este informe)